

SISTEMA DE PREDICCIÓN DE FACTORES DE RIESGO EN ADOLESCENTES SALVADOREÑOS (GSHS 2013)

Elena Sarai Serrano Fuentes
Correo electrónico: sf18004@ues.edu.sv
Irma Elena López Fuentes
Correo electrónico: lf18003@ues.edu.sv

RESUMEN: *En este trabajo se desarrolló un sistema predictivo basado en técnicas de aprendizaje automático utilizando los datos de la Encuesta Global de Salud Escolar (GSHS) de El Salvador 2013. El estudio abordó dos tareas de aprendizaje supervisado: la estimación del Índice de Masa Corporal (IMC) mediante modelos de regresión y la clasificación del riesgo en salud mental. El proceso incluyó la limpieza y transformación de datos, ingeniería de características, entrenamiento y evaluación de diferentes algoritmos predictivos. Los resultados permitieron identificar los modelos con mejor desempeño para cada problema y evidenciaron que es posible detectar patrones asociados con el estado nutricional y la salud mental de los adolescentes. Estos hallazgos demuestran el potencial del aprendizaje automático como herramienta de apoyo para orientar programas preventivos y la toma de decisiones del Ministerio de Salud.*

PALABRAS CLAVE: GSHS, Índice de Masa Corporal, Salud Mental.

1 INTRODUCCIÓN

La adolescencia representa una etapa crítica del desarrollo humano en la que se establecen hábitos y comportamientos que influyen directamente en la salud durante la vida adulta. Factores como una alimentación inadecuada, el sedentarismo, el consumo de alcohol, la violencia, el acoso escolar y los problemas de salud mental incrementan el riesgo de desarrollar enfermedades no transmisibles y trastornos psicológicos, por lo que su identificación temprana constituye una prioridad para los sistemas de salud pública.

Con el objetivo de proporcionar información confiable para el diseño de políticas sanitarias dirigidas a esta población, la Organización Mundial de la Salud (OMS), en colaboración con los Centros para el Control y la Prevención de Enfermedades (CDC) y otros organismos internacionales, desarrolló la Global School-based Student Health Survey (GSHS). Esta encuesta internacional está orientada a estudiantes de 13 a 17 años y emplea un cuestionario estandarizado para recopilar información sobre factores de riesgo y factores protectores relacionados con diez áreas fundamentales de la salud, entre ellas la alimentación, la actividad

física, la salud mental, el consumo de alcohol y drogas, la violencia, la higiene y otros comportamientos asociados con las principales causas de morbilidad y mortalidad en adolescentes [1].

La disponibilidad de este tipo de información ha impulsado la aplicación de técnicas de Machine Learning en el ámbito de la salud, debido a su capacidad para identificar patrones complejos y construir modelos predictivos que complementan los métodos tradicionales de análisis estadístico. Estos modelos permiten estimar variables de interés y detectar grupos de población con mayor probabilidad de presentar condiciones de riesgo, favoreciendo la planificación de intervenciones preventivas basadas en evidencia.

En este contexto, el presente trabajo desarrolla un sistema predictivo utilizando los datos de la encuesta GSHS El Salvador 2013, con el propósito de resolver dos problemas de aprendizaje supervisado. El primero consiste en estimar el Índice de Masa Corporal (IMC) mediante modelos de regresión a partir de variables relacionadas con hábitos y estilos de vida, evitando el uso directo del peso y la estatura para prevenir fuga de información (data leakage). El segundo consiste en clasificar el riesgo en salud mental mediante modelos de clasificación construidos a partir de variables relacionadas con factores personales, familiares y sociales presentes en la encuesta.

Para alcanzar estos objetivos se implementó un proceso integral que comprendió la limpieza y transformación de los datos, el análisis exploratorio, la ingeniería de características, el entrenamiento y evaluación de diferentes algoritmos de aprendizaje automático y la comparación de su desempeño mediante métricas específicas para problemas de regresión y clasificación. Finalmente, los resultados obtenidos se analizan desde una perspectiva de salud pública, evidenciando el potencial de estas técnicas como herramientas de apoyo para la toma de decisiones y el diseño de estrategias preventivas dirigidas a la población adolescente salvadoreña.

2 MARCO TEÓRICO

2.1 MACHINE LEARNING APLICADO A LA SALUD

El aprendizaje automático (*Machine Learning*) se ha convertido en una de las tecnologías con mayor impacto dentro del sector sanitario debido a su capacidad para analizar grandes volúmenes de datos clínicos, identificar patrones complejos y generar modelos predictivos que apoyan la toma de decisiones médicas. A diferencia de los métodos estadísticos tradicionales, los algoritmos de Machine Learning pueden aprender relaciones entre múltiples variables y mejorar su desempeño conforme disponen de nuevos datos, permitiendo desarrollar sistemas capaces de estimar riesgos, apoyar diagnósticos y predecir la evolución de diversas enfermedades [2].

Actualmente, el incremento en la disponibilidad de datos provenientes de historias clínicas electrónicas, registros hospitalarios, dispositivos portátiles (*wearables*) y sistemas de vigilancia epidemiológica ha impulsado el desarrollo de modelos predictivos aplicados a la salud. Una revisión sistemática publicada en JMIR Medical Informatics señala que algoritmos como Random Forest, Regresión Logística y Support Vector Machine son los más utilizados para la predicción y gestión de enfermedades, debido a su capacidad para procesar datos del mundo real y apoyar la medicina preventiva y personalizada [3].

Una de las principales ventajas del Machine Learning en el ámbito sanitario consiste en la detección temprana de factores de riesgo antes de que una enfermedad se manifieste clínicamente. Estos modelos permiten analizar simultáneamente variables relacionadas con antecedentes médicos, hábitos de vida, factores ambientales y características demográficas, identificando patrones que difícilmente pueden ser detectados mediante el análisis convencional. De esta manera, los sistemas predictivos contribuyen a priorizar pacientes, orientar campañas de prevención y optimizar la asignación de recursos dentro de los servicios de salud [4].

En el presente trabajo, estas capacidades se aplican al análisis de la información recopilada por la encuesta Global School-based Student Health Survey (GSHS), utilizando técnicas de aprendizaje supervisado para estimar el Índice de Masa Corporal (IMC) y clasificar el riesgo en salud mental de adolescentes salvadoreños. El desarrollo de estos modelos busca demostrar el potencial del Machine Learning como herramienta de apoyo para la formulación de estrategias preventivas y la toma de decisiones basada en evidencia.

2.2 MACHINE LEARNING APLICADO A LA SALUD MENTAL

La salud mental constituye uno de los principales desafíos para los sistemas sanitarios a nivel mundial, especialmente durante la adolescencia, etapa en la que

suelen manifestarse los primeros síntomas de trastornos como la depresión, la ansiedad y otros problemas emocionales. La identificación temprana de estos factores de riesgo permite implementar estrategias preventivas y brindar intervenciones oportunas que contribuyan a mejorar la calidad de vida de los jóvenes [5].

En los últimos años, las técnicas de Machine Learning han demostrado un gran potencial para apoyar el diagnóstico y la predicción de trastornos de salud mental. Diversas investigaciones han evidenciado que algoritmos de aprendizaje supervisado permiten analizar simultáneamente información clínica, biomarcadores, hábitos de vida y variables ambientales para identificar patrones asociados con la depresión y otros trastornos psicológicos. Estos modelos facilitan la clasificación de pacientes, la estimación del riesgo y la identificación de subgrupos con características clínicas similares, favoreciendo una atención médica más personalizada [6].

Asimismo, estudios recientes destacan que la incorporación de variables relacionadas con el estilo de vida, el consumo de alcohol, la actividad física y otros factores conductuales mejora significativamente la capacidad predictiva de los modelos de aprendizaje automático. La combinación de estas variables con técnicas de inteligencia artificial permite desarrollar herramientas de apoyo para profesionales de la salud, orientadas a la detección temprana y al diseño de intervenciones preventivas basadas en evidencia [5].

En el presente trabajo, estos principios se aplican al análisis de la encuesta Global School-based Student Health Survey (GSHS), utilizando variables asociadas con factores personales, familiares y sociales para construir un modelo capaz de clasificar el riesgo en salud mental de adolescentes salvadoreños. Este enfoque busca demostrar el potencial del aprendizaje automático como herramienta de apoyo para fortalecer la vigilancia epidemiológica y la toma de decisiones en salud pública.

3 METODOLOGÍA

3.1 RECOLECCIÓN DE DATOS

Para el desarrollo del sistema predictivo se utilizó la base de datos Global School-based Student Health Survey (GSHS) El Salvador 2013, proporcionada por la Organización Mundial de la Salud (OMS). El conjunto de datos contiene información recopilada mediante encuestas aplicadas a estudiantes adolescentes e incluye variables relacionadas con alimentación, actividad física, salud mental, consumo de alcohol, violencia, higiene y factores de protección familiar [1].

3.2 ANÁLISIS EXPLORATORIO DE DATOS

Como primera etapa se realizó un Análisis Exploratorio de Datos (EDA) con el propósito de comprender la estructura del conjunto de datos, identificar la distribución de las variables y detectar

posibles problemas de calidad de la información. Durante esta fase se analizaron las variables demográficas, los patrones de valores faltantes y las relaciones existentes entre las variables de interés mediante estadísticas descriptivas y representaciones gráficas. Este análisis permitió seleccionar las variables con mayor relevancia para el desarrollo de los modelos predictivos.

3.3 Preprocesamiento de datos

Posteriormente se llevó a cabo un proceso de limpieza y preparación de los datos. Se reemplazaron los valores utilizados para representar datos faltantes por valores nulos, se eliminaron registros y variables con información insuficiente y se realizaron transformaciones para garantizar la consistencia de los datos.

3.4 Construcción de variables objetivo

Con el conjunto de datos previamente procesado se definieron dos problemas de aprendizaje supervisado. Para la tarea de regresión se construyó la variable objetivo correspondiente al Índice de Masa Corporal (IMC), calculada a partir de la información de peso y estatura disponible en la encuesta. Posteriormente, estas variables fueron excluidas del conjunto de entrenamiento para evitar fuga de información (*data leakage*) y garantizar que el modelo realizara sus predicciones únicamente a partir de variables relacionadas con los hábitos y estilos de vida de los estudiantes.

Para la tarea de clasificación se construyó la variable binaria Riesgo_Salud_Mental, derivada de la variable QN24, la cual identifica la presencia de ideación suicida durante los últimos doce meses. Esta variable permitió clasificar a los estudiantes en dos categorías: Riesgo y No Riesgo, constituyendo la variable objetivo utilizada durante el entrenamiento de los modelos de clasificación.

3.5 Entrenamiento y evaluación de modelos

Una vez definidos los conjuntos de datos, se entrenaron diferentes modelos de aprendizaje supervisado para resolver cada una de las tareas propuestas. Para la estimación del IMC se evaluaron modelos de Regresión Lineal, Random Forest Regressor y Gradient Boosting Regressor, considerando diferentes estrategias de selección de variables. El desempeño fue comparado mediante las métricas RMSE, MAE y coeficiente de determinación (R^2).

Para la clasificación del riesgo en salud mental se implementaron modelos de Regresión Logística, Árbol de Decisión, Random Forest y Gradient Boosting. Debido al desbalance existente entre las clases, se empleó el parámetro `class_weight="balanced"` cuando fue posible y se priorizó la evaluación mediante el F1-Score de la clase minoritaria y el Área Bajo la Curva ROC (AUC-ROC), métricas adecuadas para problemas de clasificación desbalanceada.

4 RESULTADOS

En esta sección se presentan los resultados obtenidos para las dos tareas propuestas en el laboratorio. La primera corresponde a la predicción del Índice de Masa Corporal (IMC) mediante modelos de regresión, mientras que la segunda se enfoca en la clasificación del riesgo en salud mental utilizando algoritmos de aprendizaje supervisado.

4.1 ÍNDICE DE MASA CORPORAL

Se evaluaron cuatro estrategias de selección de variables (Baseline, Dominio, Ampliado y Optimizado), combinadas con tres algoritmos de regresión: Regresión Lineal, Random Forest Regressor y Gradient Boosting Regressor. Los resultados obtenidos muestran que la Regresión Lineal utilizando variables seleccionadas mediante conocimiento del dominio obtuvo el mejor desempeño, alcanzando el menor RMSE y el mayor coeficiente de determinación entre todos los modelos evaluados.

Figura 1. Comparación de modelos de regresión según RMSE





Figura 2. Comparación de modelos de regresión según R^2




Debido a que presentó el menor error de predicción (RMSE = 3.893), el menor MAE (2.985) y el mayor valor de R^2 (0.0199), la Regresión Lineal basada en conocimiento del dominio fue seleccionada como modelo final para la estimación del IMC.

4.1.1 IMPORTANCIA DE VARIABLES

La Figura 3 muestra la importancia relativa de las variables empleadas por el modelo seleccionado. Se observa que las variables relacionadas con la actividad física, el consumo de bebidas azucaradas, el consumo de frutas, el sedentarismo y el consumo de vegetales

presentan la mayor contribución en la predicción del IMC.

Figura 3. Importancia de variables para la predicción del IMC



4.2 RIESGO EN SALUD MENTAL

La segunda tarea del laboratorio consistió en desarrollar un modelo de clasificación capaz de identificar estudiantes con riesgo en salud mental utilizando la variable objetivo Riesgo_Salud_Mental, construida a partir de la variable QN24 correspondiente a la presencia de ideación suicida durante los últimos doce meses. Para el entrenamiento de los modelos se utilizaron variables relacionadas con el consumo de alcohol, experiencias de bullying, relación con los padres y variables demográficas.

El análisis exploratorio evidenció un conjunto de datos desbalanceado, conformado por 1,622 estudiantes clasificados como "No Riesgo" (86 %) y 267 estudiantes clasificados como "Riesgo" (14 %), como se muestra en la Tabla 1. Debido a esta distribución, la exactitud (Accuracy) no fue utilizada como principal criterio de evaluación, priorizando el F1-Score y el AUC-ROC, métricas más apropiadas para este tipo de problemas.

Tabla 1. Distribución de la variable objetivo

Clase	Cantidad	Porcentaje
No riesgo	1622	86%
Riesgo	267	14%

Tabla 2. Comparación de modelos

Modelo	F1	AUC
Regresión Logística	0.391	0.735
Random Forest	0.37	0.737
Árbol	0.319	0.67
Gradient Boosting	0.219	0.724

5 CONCLUSIONES

En este trabajo se desarrolló un sistema predictivo basado en técnicas de aprendizaje automático utilizando la base de datos Global School-based Student Health Survey (GSHS) El Salvador 2013, con el propósito de abordar dos problemas de aprendizaje supervisado relacionados con la salud de adolescentes salvadoreños.

Para la tarea de regresión, la Regresión Lineal utilizando variables seleccionadas mediante conocimiento del dominio obtuvo el mejor desempeño, alcanzando un RMSE de 3.893, un MAE de 2.985 y un R^2 de 0.0199. Aunque la capacidad explicativa del modelo fue limitada, los resultados muestran que los hábitos alimenticios y el nivel de actividad física aportan información relevante para la estimación del Índice de Masa Corporal.

En la tarea de clasificación, la Regresión Logística fue seleccionada como modelo final al obtener el mayor F1-Score (0.391) para la clase minoritaria y un AUC-ROC de 0.735, demostrando que variables relacionadas con el consumo de alcohol, el bullying y el entorno familiar permiten identificar patrones asociados con el riesgo en salud mental.

Finalmente, los resultados obtenidos evidencian el potencial del aprendizaje automático como herramienta de apoyo para la detección temprana de factores de riesgo en adolescentes. Como trabajo futuro, se recomienda incorporar nuevas variables clínicas, socioeconómicas y familiares, así como explorar técnicas más avanzadas de aprendizaje automático que permitan mejorar la capacidad predictiva de los modelos desarrollados.

6 REFERENCIAS

- [1] World Health Organization, "Global School-based Student Health Survey (GSHS)," World Health Organization. [En línea]. Disponible en: <https://www.who.int/teams/noncommunicable-diseases/surveillance/systems-tools/global-school-based-student-health-survey>.
- [2] Campus Health Tech, "¿Se puede predecir enfermedades con Machine Learning?," Campus Health Tech, 2024. [En línea]. Disponible en: <https://campushealthtech.com/blog/se-puede-predecir-enfermedades-con-machine-learning/>.
- [3] N. H. Alhumaidi, D. Dermawan, H. F. Kamaruzaman and N. Alotaqi, "The Use of Machine Learning for Analyzing Real-World Data in Disease Prediction and Management: Systematic Review," JMIIR Medical Informatics, vol. 13, e68898, 2025.
- [4] Centro de Investigación e Innovación en Inteligencia Artificial (CIIIA), "Machine Learning y el diagnóstico temprano de enfermedades," CIIIA, 2025. [En línea]. Disponible en: <https://www.ciiia.mx/noticiasciiia/machine-learning-diagnostico-temprano-enfermedades>.
- [5] J. A. Reátegui-Rivera et al., "Machine Learning aplicado a la predicción de la salud mental: una revisión de la literatura," Revista de Investigación de Sistemas e Informática, vol. 28, no. 2, 2025.
- [6] Universidad Autónoma de Madrid, "El machine learning ayuda a identificar la depresión," Universidad Autónoma de Madrid, 13-feb-2023. [En línea]. Disponible en: <https://www.uam.es/uam/investigacion/cultura-cientifica/noticias/machine-learning-depresion>.
- [7] Scikit-learn Developers, "Scikit-learn: Machine Learning in Python," [En línea]. Disponible en: <https://scikit-learn.org/>.

7 ANEXOS

Repositorio oficial del proyecto:

<https://github.com/ielopezf/SISTEMA-PREDICTIVO-DE-FACTORES-DE-RIESGO-EN-ADOLESCENTES-SALVADORE-OS-.git>

El cuaderno Jupyter utilizado para el desarrollo y simulación del proyecto se encuentra incluido dentro del repositorio GitHub.

Entorno Jupyter de desarrollo (acceso temporal):

167.86.123.214